

湖北大学 2025—2026 学年度第 2 学期课程考查试题纸

The paper of course exam

Name: Big Data Analysis and Applications
Content: Course Report
Teacher: Li Jie

课程报告题目

《数字生活方式下的高风险识别、数字依赖预测与用户画像分析——基于
2025 Digital Lifestyle Benchmark 数据集的分类、回归与聚类研究》

学号: _____
姓名: _____
学院: _____
专业年级: _____
Institution: _____
Grade and major: _____

Teacher's comments: _____

Total score: _____
Grading teacher: _____

摘要

本文基于 2025 Digital Lifestyle Benchmark Dataset，分析数字设备使用、社交媒体、通知、睡眠与活动习惯的建模价值。数据集包含 3500 条记录和 24 个字段，为合成基准数据，本文结论仅用于课程建模和行为分析，不用于医学诊断。研究设置三类任务：分类任务预测 `high_risk_flag` 以进行高风险筛查；回归任务以 `digital_dependence_score` 为主线，并保留 `productivity_score` 作为弱预测/负结果；聚类任务基于数字行为与生活习惯形成探索性画像。结果显示，分类最终采用 Gradient Boosting，threshold=0.14 时测试集 Recall=0.6420、F1=0.5355、PR-AUC=0.5084；数字依赖预测 $R^2 = 0.9839$ 、MSE=3.1471、MAE=0.9982；生产力得分预测 $R^2 = -0.0041$ ；KMeans $k = 3$ 的 Silhouette=0.1860，聚类仅作探索性画像。

关键词：数字生活方式；高风险识别；数字依赖预测；机器学习；聚类画像；大数据分析

目录

1	研究背景与问题定义	4
1.1	研究问题	4
1.2	任务设计	4
1.3	实验约束	4
2	数据集选择与合规性说明	5
2.1	数据来源与基本信息	5
2.2	字段与任务适配性	5
2.3	备选数据集未采用原因	6
3	数据预处理	6
3.1	数据质量检查	6
3.2	特征工程	7
3.3	目标泄漏控制	8
4	探索性分析与数据可视化	8
4.1	高风险标签分布	8
4.2	数值变量相关性	9
4.3	风险组行为差异	10
4.4	类别变量风险率	11
5	分类实验：高风险数字生活方式筛查	12
5.1	任务设定与模型	12
5.2	调参与阈值选择	13
5.3	测试集表现	13
5.4	分类结果解释	17
6	回归实验：数字依赖预测与生产力弱预测检验	17
6.1	任务设定与模型	18
6.2	digital_dependence_score 预测	18
6.3	productivity_score 弱预测结果	20
6.4	回归目标对比	21
7	聚类实验：数字生活方式用户画像分析	21
7.1	聚类输入与标准化	21
7.2	算法对比与簇数选择	22
7.3	PCA 可视化与解释方差	23

7.4 用户画像解释	25
8 综合结果分析与业务建议	25
8.1 三类任务的共同信息	26
8.2 数字生活方式管理建议	26
8.3 方法局限	26
9 总结与个人反思	27
9.1 主要结论	27
9.2 课程收获	27
9.3 改进方向	28
A 附录：核心代码与复现实验说明	28
A.1 项目代码结构	28
A.2 Notebook 执行顺序	28
A.3 附录图表	29
A.4 附录表格与结果文件	32
A.5 参考资料与数据来源	33

1 研究背景与问题定义

本章的目的在于说明研究问题的来源和建模边界。移动设备、社交媒体平台、即时通知和在线学习工具已经嵌入日常生活，用户的设备使用时长、手机解锁次数、通知暴露、社交媒体使用、睡眠质量和身体活动之间可能存在复杂关联。对这些变量进行数据分析，有助于从课程实践角度理解数字生活方式数据如何支持风险筛查、行为指标预测和用户画像构建。

需要强调的是，本文使用的数据为合成教学/基准数据，研究目标是完成《大数据分析与应用》课程中的数据处理、可视化和机器学习建模训练。报告中的“高风险”仅对应数据集中的 `high_risk_flag` 标签，不代表医学诊断结论；模型输出也不能直接用于个体健康判断或自动化干预。

1.1 研究问题

围绕数字生活方式变量，本文设置四个研究问题：

- Q1: 在排除心理状态、效率得分和数字依赖得分等潜在泄漏字段后，能否对 `high_risk_flag` 进行高风险数字生活方式筛查？
- Q2: 使用人口背景、数字行为、生活习惯和工程特征，能否稳定预测 `digital_dependence_score`？
- Q3: `productivity_score` 是否能被当前可观测特征稳定预测，若不能，负结果本身说明什么？
- Q4: 只基于数字行为与生活习惯数值特征，能否形成具有解释价值的探索性用户画像？

1.2 任务设计

为回答上述问题，本文将实验组织为三类机器学习任务。分类任务预测 `high_risk_flag`，重点关注 Recall、F1、PR-AUC 和混淆矩阵，因为高风险筛查中漏判会降低模型的实际参考价值。回归任务以 `digital_dependence_score` 为主线，同时保留 `productivity_score` 作为对照，以检验不同目标变量在同一特征体系下的可预测性差异。聚类任务只使用数字行为和生活习惯数值特征，在不使用结果变量参与训练的前提下形成用户画像，再用风险比例、数字依赖得分和效率得分进行事后解释。

1.3 实验约束

全部实验使用 Python、pandas、numpy、scipy、scikit-learn 与 matplotlib，在 CPU 环境下运行，不使用深度学习模型。随机过程统一设置 `random_state=42`，以保证结果

可复现。正文中所有指标均来自 `results/` 目录下已有 CSV 或文本文件，不对未运行的实验作推断。

2 数据集选择与合规性说明

本章的目的在于说明数据集来源、规模、字段结构和使用限制。课程要求数据集来自公开数据平台、具备足够样本量和字段数，并能自然支持至少两类机器学习任务。本文最终采用 2025 Digital Lifestyle Benchmark Dataset，原因是该数据集直接围绕数字生活方式主题构建，字段覆盖设备使用、睡眠活动、心理状态、高风险标签、生产力得分和数字依赖得分，能够支持分类、回归与聚类三类任务。

2.1 数据来源与基本信息

本文数据来源于 Hugging Face 数据集页面，数据格式为 CSV。表 1 汇总了数据集的合规性信息。根据 `results/dataset_compliance_summary.csv`，该数据集共有 3500 条记录、24 个字段，许可证记录为 CC BY 4.0，实验设置为 CPU only 且不使用深度学习。

表 1: 数据集合规性与基本信息汇总

项目	内容
数据集名称	2025 Digital Lifestyle Benchmark Dataset
来源页面	Hugging Face 数据集页面
数据格式	CSV
样本量	3500 条记录
字段数	24 个字段
许可证	CC BY 4.0
随机种子	42
运行约束	CPU only, 非深度学习

该数据集为合成数据，适合用于 benchmark、课程实验、EDA 和机器学习流程训练。由于数据不是来自真实医疗或临床追踪场景，本文只讨论数字生活方式变量与建模目标之间的统计关系和预测表现，不将其解释为真实世界中的医学诊断证据。

2.2 字段与任务适配性

数据字段包括人口背景变量、数字行为变量、生活习惯变量和结果变量。例如，数字行为字段包含 `device_hours_per_day`、`phone_unlocks`、`notifications_per_day`、

social_media_mins; 生活习惯字段包含 study_mins、physical_activity_days、sleep_hours、sleep_quality。结果变量包括 high_risk_flag、productivity_score 和 digital_dependence_score。

这些字段使数据集能够自然对应本文三类任务：high_risk_flag 可作为二分类目标，digital_dependence_score 和 productivity_score 可作为回归目标，数字行为和生活习惯字段可作为聚类输入。这样的任务结构比单一监督学习数据集更适合期末综合报告。

2.3 备选数据集未采用原因

前期曾考虑使用 pfm_train.csv 和 pfm_test.csv。但该数据集来源和发布时间不如本项目最终采用的数据集稳定，且任务形式与实验三中的员工离职预测较为相似，难以体现本次课程报告的独立主题和综合建模设计。相比之下，2025 Digital Lifestyle Benchmark Dataset 与“数字生活方式”主题更贴合，也更容易在同一数据框架下组织分类、回归和聚类实验。

3 数据预处理

本章的目的在于说明数据进入模型前如何检查质量、构造特征并控制目标泄漏。预处理不是简单的格式整理，而是保证后续结果可信的基础：若缺失、重复、异常范围或目标泄漏未处理，分类、回归和聚类结果都会被扭曲。

3.1 数据质量检查

预处理质量检查结果保存于 results/preprocessing_quality_check.csv。表 2 给出精简汇总。检查结果显示，原始数据包含 3500 条记录和 24 个字段，缺失值总数为 0，重复行数量为 0，重复 id 数量为 0。对年龄、设备使用时长、手机解锁、通知数、社交媒体时长、学习时长、运动天数、睡眠时长、睡眠质量、生产力得分和数字依赖得分等数值字段进行合理范围检查后，未发现需要删除的记录。

表 2: 预处理质量检查精简汇总

检查项	结果
原始样本量	3500
原始字段数	24
缺失值总数	0
重复行数量	0
重复 id 数量	0
关键数值字段范围检查	未发现需删除记录
工程特征生成	7 个派生特征均成功生成
分类特征控制	排除目标列、心理状态、效率和数字依赖字段
回归特征控制	排除 high_risk_flag 与其他 outcome 字段
聚类特征控制	仅使用数字行为与生活习惯数值特征

因为没有发现缺失、重复或严重异常，本研究没有强行删除样本。保留完整样本有助于减少人为处理对分布的影响，也与后续可复现实验要求一致。

3.2 特征工程

原始字段能够描述数字生活方式的基础状态，但部分关系需要通过派生特征表达。例如，单纯的通知总数不能反映单位设备使用时间内的通知密度，社交媒体分钟数和学习分钟数也可以转换为小时或比例。本文据此生成了 `social_media_hours`、`study_hours`、`notifications_per_device_hour`、`unlocks_per_device_hour`、`device_to_sleep_ratio`、`activity_sleep_interaction` 和 `social_to_study_ratio`。质量检查表显示这些工程特征均已成功生成。

Listing 1: 行为与生活习惯工程特征示例

```
def add_behavior_features(df):
    out = df.copy()
    eps = 1e-6
    out["social_media_hours"] = out["social_media_mins"] / 60.0
    out["notifications_per_device_hour"] = (
        out["notifications_per_day"] / out["device_hours_per_day"].clip(lower=eps)
    )
    out["device_to_sleep_ratio"] = (
        out["device_hours_per_day"] / out["sleep_hours"].clip(lower=eps)
    )
    return out
```


3.3 目标泄漏控制

目标泄漏控制是本文建模流程的重点。分类任务预测 `high_risk_flag` 时，主模型不使用 `anxiety_score`、`depression_score`、`stress_level`、`happiness_score`、`focus_score`、`productivity_score` 和 `digital_dependence_score`，因为这些变量属于心理、效率或结果性质字段，若直接输入模型，会高估高风险筛查能力。

回归任务同样排除 `high_risk_flag` 和其他 `outcome` 字段；当预测 `digital_dependence_score` 时，不使用 `productivity_score` 等结果变量；当预测 `productivity_score` 时，也不使用 `digital_dependence_score`。聚类任务则只使用数字行为与生活习惯数值特征，不将人口背景类别变量、设备类别变量和任何结果变量放入聚类训练。

Listing 2: 任务级特征排除逻辑示例

```
if task == "classification":
    excluded.add(CLASSIFICATION_TARGET)
    excluded.update(HIGH_RISK_LEAKAGE_COLUMNS)
elif task == "regression":
    excluded.add(target)
    excluded.update(OUTCOME_COLUMNS)
elif task == "clustering":
    X = data[get_clustering_feature_columns(data)].copy()
```

上述规则使三类任务的输入空间保持一致、可解释且尽量避免结果变量反向进入模型。

4 探索性分析与数据可视化

本章的目的在于通过可视化理解样本分布、变量相关性和不同群体之间的描述性差异。EDA 不直接证明因果关系，但可以帮助确定模型任务的难点，例如类别不均衡、变量相关性和风险组之间的行为差异。

4.1 高风险标签分布

图 1 展示了 `high_risk_flag` 的类别分布。结果文件 `results/eda_high_risk_flag_distribution.csv` 显示，低风险样本为 2795 条，占 79.86%；高风险样本为 705 条，占 20.14%。这说明分类任务存在一定类别不均衡，如果只看 Accuracy，模型可能偏向多数类。因此后续分类实验需要同时报告 Recall、F1、PR-AUC 和混淆矩阵。




图 1: high_risk_flag 类别分布

4.2 数值变量相关性

图 2 展示主要数值变量之间的相关性结构。该图用于观察数字行为、睡眠活动和结果变量之间是否存在较强线性关联，也用于提醒后续模型解释时注意变量之间可能存在共线性。相关性图只能说明变量之间的统计关联强弱，不能说明设备使用、睡眠或通知数量对结果变量存在因果作用。




图 2: 数值变量相关性热力图

4.3 风险组行为差异

图 3 按 `high_risk_flag` 对核心行为变量进行箱线图比较。根据 `results/eda_group_comparison_summary.csv`, 高风险组的日均设备使用时长均值为 9.47 小时, 非高风险组为 6.77 小时; 高风险组手机解锁次数均值为 186.92 次, 非高风险组为 137.06 次; 高风险组睡眠时长均值为 6.50 小时, 非高风险组为 7.45 小时。这些差异为分类模型提供了可解释的行为线索, 但仍应理解为描述性差异。




图 3: 按高风险标签分组的行为变量箱线图

4.4 类别变量风险率

图 4 汇总了性别、地区、收入水平、教育水平、日常角色和设备类型等类别变量下的高风险比例。该图的作用不是给某个群体贴标签，而是检查类别变量是否可能对模型产生分组差异。由于数据为合成数据，类别风险率仅用于描述样本结构和辅助建模解释，不用于真实人群判断。




图 4: 类别变量分组风险率

5 分类实验：高风险数字生活方式筛查

本章的目的在于回答 Q1: 在排除明显泄漏字段后, 模型能否对 `high_risk_flag` 进行有参考价值的筛查。由于该任务涉及“高风险”标签, 本文不将模型表述为诊断工具, 而将其定位为课程实验中的风险筛查模型。

5.1 任务设定与模型

分类目标为 `high_risk_flag`。输入特征排除了 `id`、目标列以及 `anxiety_score`、`depression_score`、`stress_level`、`happiness_score`、`focus_score`、`productivity_score`、`digital_dependence_score` 等字段。这样做的原因是这些变量与风险标签或结果状态高度接近, 若直接作为输入, 会使模型在测试集中表现得过于乐观。

候选模型包括 Logistic Regression、Random Forest 和 Gradient Boosting。调参使用 5 折交叉验证, 其中分类交叉验证采用 StratifiedKFold, 以保持每折中高风险样本比

例相对稳定。评价指标包括 Accuracy、Precision、Recall、F1、ROC-AUC、PR-AUC、Balanced Accuracy 和混淆矩阵。

5.2 调参与阈值选择

表 3 展示验证集上的阈值调优结果。默认阈值 0.50 的 Precision 较高，但 Recall 较低；当阈值降低时，模型会识别出更多高风险样本，但误报数量也会上升。本文最终采用验证集中“Recall 至少达到 0.60 且 Precision 相对较优”的策略，对应 Gradient Boosting 和 threshold=0.14。选择该策略的原因是高风险筛查不能只追求总体准确率，需要在漏判和误报之间做明确权衡。

表 3: 验证集阈值调优结果

模型	阈值策略	阈值	Precision	Recall	F1	PR-AUC	Balanced Accuracy
gradient_boosting	default_0_50	0.5000	0.6429	0.2045	0.3103	0.4805	0.5880
gradient_boosting	max_f1	0.3500	0.5752	0.4924	0.5306	0.4805	0.7005
gradient_boosting	recall_at_least_60_best_precision	0.1400	0.4175	0.6136	0.4969	0.4805	0.6992
gradient_boosting	recall_at_least_70_best_precision	0.1200	0.2636	0.7727	0.3931	0.4805	0.6149

5.3 测试集表现

表 4 给出 Gradient Boosting 在测试集不同阈值策略下的表现。最终策略 threshold=0.14 时，测试集 Precision=0.4593、Recall=0.6420、F1=0.5355、PR-AUC=0.5084、ROC-AUC=0.7531、Balanced Accuracy=0.7259。与默认阈值相比，该策略牺牲了一部分 Precision，但显著提高了高风险样本召回率，更符合筛查任务的解释口径。

表 4: 测试集分类指标与阈值策略对比

模型	阈值策略	阈值	Precision	Recall	F1	ROC-AUC	PR-AUC	Balanced Accuracy
gradient_boosting	default_0_50	0.5000	0.6812	0.2670	0.3837	0.7531	0.5084	0.6178
gradient_boosting	max_f1	0.3500	0.5957	0.4773	0.5300	0.7531	0.5084	0.6979
gradient_boosting	recall_at_least_60_best_precision	0.1400	0.4593	0.6420	0.5355	0.7531	0.5084	0.7259
gradient_boosting	recall_at_least_70_best_precision	0.1200	0.2536	0.7955	0.3846	0.7531	0.5084	0.6030

图 5 直观比较了不同阈值策略下的指标变化。该图说明分类模型本身输出的是概率，最终业务策略并不必然固定在 0.50 阈值。阈值越低，模型越倾向于把样本判为高风险，因此 Recall 可能提高，但 Precision 会下降。



图 5: 分类阈值策略指标对比

图 6 为最终阈值下的混淆矩阵。测试集中实际非高风险样本中有 566 个被正确识别，133 个被误判为高风险；实际高风险样本中有 113 个被识别，63 个被漏判。这个结果说明模型具有一定筛查能力，但仍存在误报和漏判，因此不能替代人工复核或专业判断。




图 6: 最终分类模型混淆矩阵

图 7 和图 8 分别展示 Precision-Recall 曲线和 ROC 曲线。由于高风险样本比例约为 20.14%，PR-AUC 对少数类识别更敏感；ROC-AUC 则从整体排序能力角度评价概率输出。本文同时报告两类曲线，是为了避免只用单一指标评价筛查模型。




图 7: 最终分类模型 Precision-Recall 曲线




图 8: 最终分类模型 ROC 曲线

5.4 分类结果解释

综合来看，Gradient Boosting 在调参后被选为最终概率模型，threshold=0.14 的策略使 Recall 达到 0.6420，说明模型能识别出约六成以上的测试集高风险样本。但 Precision=0.4593 也说明被判为高风险的样本中存在较多误报。因此，本报告将其解释为“可辅助筛查”的模型，而不是“可独立判定风险状态”的模型。

6 回归实验：数字依赖预测与生产力弱预测检验

本章的目的在于回答 Q2 和 Q3：当前特征能否稳定预测数字依赖程度，以及同样的特征是否也能稳定预测生产力得分。为了避免事后只呈现效果好的结果，本文同时保留两个回归目标，并明确将 `digital_dependence_score` 作为主线，将 `productivity_score` 作为弱预测/负结果分析。

6.1 任务设定与模型

回归输入包括人口背景、数字行为、生活习惯和工程特征，但不使用 `high_risk_flag`、心理状态结果变量以及另一个 `outcome` 目标变量。模型包括 Linear Regression、Ridge Regression、Random Forest Regressor 和 Gradient Boosting Regressor。调参采用 5 折交叉验证，评价指标包括 R^2 、MSE、RMSE 和 MAE。

6.2 `digital_dependence_score` 预测

表 5 展示数字依赖得分回归结果。最佳模型为 Gradient Boosting，测试集 $R^2 = 0.9839$ 、MSE=3.1471、RMSE=1.7740、MAE=0.9982。该结果说明，在当前合成数据设定下，数字依赖得分与设备使用时长、通知数量、手机解锁等变量之间存在很强的可预测关系。

表 5: `digital_dependence_score` 回归模型测试集指标

模型	CV 最优 R^2	MAE	MSE	RMSE	R^2
<code>gradient_boosting</code>	0.9804	0.9982	3.1471	1.7740	0.9839
<code>ridge</code>	0.9692	0.7652	3.6541	1.9116	0.9813
<code>linear_regression</code>	0.9692	0.7651	3.6538	1.9115	0.9813
<code>random_forest</code>	0.9680	1.2680	4.3875	2.0946	0.9776

图 9 展示真实值与预测值的关系。点云靠近对角线，说明模型预测值与真实数字依赖得分具有较高一致性。该图支持将 `digital_dependence_score` 作为回归主线，但仍不能被解释为数字行为对依赖程度的因果证明。




图 9: 数字依赖分数真实值与预测值对比

图 10 给出置换重要性结果。根据数字依赖置换重要性 CSV, `device_hours_per_day`、`notifications_per_day` 和 `phone_unlocks` 排在前列。这与数字依赖得分的业务含义一致：设备使用、通知暴露和解锁频率更直接地反映数字设备依赖程度。




图 10: 数字依赖回归任务置换重要性

6.3 productivity_score 弱预测结果

表 6 展示生产力得分回归结果。最佳模型同样为 Gradient Boosting，但测试集 $R^2 = -0.0041$ 、MSE=85.2031、RMSE=9.2306、MAE=7.1671。负的 R^2 表示模型在测试集上的解释能力弱于简单预测均值，因此不能写成“数字生活方式可以有效预测生产力得分”。

表 6: productivity_score 回归模型测试集指标

模型	CV 最优 R^2	MAE	MSE	RMSE	R^2
gradient_boosting	0.0119	7.1671	85.2031	9.2306	-0.0041
random_forest	0.0072	7.2088	85.9208	9.2693	-0.0125
ridge	0.0043	7.1747	85.5884	9.2514	-0.0086
linear_regression	0.0002	7.1999	85.8232	9.2641	-0.0114

该负结果具有报告价值。它说明同一组数字行为与生活习惯特征并不一定适合预测所有目标变量。生产力得分可能受未观测因素影响，也可能在该合成数据生成机制中与行为变量关系较弱。因此，本文将 productivity_score 作为模型局限和目标可预测性差异的证据，而不是回避该结果。

6.4 回归目标对比

表 7 和图 11 汇总两个回归目标的最佳模型表现。对比结果非常清楚：digital_dependence_score 的 $R^2 = 0.9839$ ，而 productivity_score 的 $R^2 = -0.0041$ 。因此，正式报告正文以数字依赖预测为主线，生产力得分只作为辅助负结果分析。

表 7: 两个回归目标的最佳模型对比

目标变量	最佳模型	MAE	MSE	RMSE	R^2	CV 最优 R^2
productivity_score	gradient_boosting	7.1671	85.2031	9.2306	-0.0041	0.0119
digital_dependence_score	gradient_boosting	0.9982	3.1471	1.7740	0.9839	0.9804




图 11: 两个回归目标的最佳模型表现对比

7 聚类实验：数字生活方式用户画像分析

本章的目的在于回答 Q4：在不使用结果变量参与训练的情况下，能否仅根据数字行为与生活习惯形成具有解释价值的用户画像。聚类结果不代表人群天然存在严格边界，而是对生活方式模式进行探索性总结。

7.1 聚类输入与标准化

聚类输入只包含 15 个数字行为与生活习惯数值特征：device_hours_per_day、phone_unlocks、notifications_per_day、social_media_mins、study_mins、physical_activity_days、sleep_hours、sleep_quality 及相关工程特征。

训练阶段不使用 `id`、人口背景类别变量、设备类别变量、`high_risk_flag`、`digital_dependence_score`、`productivity_score` 或心理状态字段。

不同输入特征量纲差异较大，例如通知数、分钟数和睡眠质量的尺度不同，因此聚类前使用 `StandardScaler` 标准化。这样做可以避免某些数值范围较大的变量在距离计算中占据不合理优势。

7.2 算法对比与簇数选择

本文比较了 `KMeans`、`AgglomerativeClustering` 和 `GaussianMixture`。表 8 显示，`KMeans` 在 $k = 3$ 时取得最高 `Silhouette`=0.1860，`Calinski-Harabasz`=611.1770，`Davies-Bouldin`=1.7959。虽然该结果是三类算法中相对最优，但 `Silhouette` 低于 0.20，说明聚类结构并不强，不能解释为自然清晰分群。

表 8: 不同聚类算法的最佳结果对比

算法	k	Inertia	Silhouette	Calinski-Harabasz	Davies-Bouldin
agglomerative	3	—	0.1518	495.8938	1.8768
gaussian_mixture	2	—	0.1478	650.8461	2.1599
kmeans	3	38902.0591	0.1860	611.1770	1.7959

图 12 展示 `KMeans` 肘部法则。随着 k 增加，`Inertia` 持续下降，这是 `KMeans` 的常见现象；因此不能只依赖 `Inertia` 选择簇数，还需要结合 `Silhouette` 和画像可解释性。




图 12: `KMeans` 肘部法则图

图 13 展示不同算法和簇数下的轮廓系数。`KMeans` 的 $k = 3$ 在本实验中最高，但

数值只有 0.1860，进一步说明聚类边界偏弱。本报告后续仅将其作为探索性画像，而不把簇解释为严格、稳定的人群分类。




图 13: 不同聚类算法与簇数的轮廓系数

7.3 PCA 可视化与解释方差

图 14 展示了基于聚类同一组标准化特征的 PCA 累计解释方差。根据 `results/pca_explained_variance.csv`，前 2 个主成分累计解释方差约为 0.4241，前 5 个主成分约为 0.7895，前 8 个主成分约为 0.9509。PCA 在本文中主要用于降维可视化和辅助理解，不作为分类或回归模型输入，也不用于因果解释。




图 14: PCA 累计解释方差曲线

图 15 将 KMeans 聚类结果投影到 PCA 二维空间。由于前两个主成分并不能解释全部信息，二维图只能帮助观察簇的大致相对位置，不能作为判断聚类边界清晰的唯一依据。




图 15: 生活方式聚类 PCA 投影

7.4 用户画像解释

表 9 给出三类聚类画像的精简结果。Cluster 0 的社交媒体使用时长均值最高，约为 430.21 分钟/天，可命名为“高社交媒体使用型”；Cluster 1 的设备使用时长最高，约为 11.05 小时/天，数字依赖得分均值为 51.24，高风险比例为 0.3725，可命名为“高设备依赖型”；Cluster 2 的设备使用时长较低、睡眠时长和睡眠质量较高，高风险比例为 0.1142，可命名为“低负荷均衡型”。

表 9: 数字生活方式聚类画像精简表

簇	样本数	设备时长	社交媒体分钟	睡眠时长	睡眠质量	高风险比例	生产力均值	数字依赖均值	建议画像名
0	447	6.9533	430.2125	7.3816	2.7899	0.1969	65.3375	34.3296	高社交媒体使用型
1	1039	11.0538	131.8787	6.1218	1.6953	0.3725	65.9081	51.2425	高设备依赖型
2	2014	5.4711	113.4275	7.8106	3.2137	0.1142	64.9767	29.6962	低负荷均衡型

图 16 用标准化均值热力图展示各簇的行为特征差异。该图的作用是帮助读者快速比较不同画像在设备使用、社交媒体、睡眠和活动变量上的相对强弱。由于 Silhouette=0.1860，画像名称应被理解为便于讨论的解释标签，而不是严格人群边界。




图 16: 聚类画像标准化均值热力图

8 综合结果分析与业务建议

本章的目的在于把分类、回归和聚类三类任务放在同一分析框架中解释，并给出谨慎的行为管理建议。所有建议都基于模型结果和描述性统计，不使用因果化表述，也不将模型输出用于医学诊断。

8.1 三类任务的共同信息

分类任务显示，在排除结果变量泄漏后，设备使用时长、睡眠时长和相关工程特征仍能为高风险筛查提供一定信息。最终 Gradient Boosting 在 $\text{threshold}=0.14$ 下取得 $\text{Recall}=0.6420$ 和 $\text{F1}=0.5355$ ，说明模型可以识别一部分高风险样本，但仍存在 63 个漏判和 133 个误报。

回归任务显示，不同目标变量的可预测性差异很大。`digital_dependence_score` 的最佳 $R^2 = 0.9839$ ，说明该目标在当前合成数据中与设备使用、通知和解锁变量高度一致；而 `productivity_score` 的最佳 $R^2 = -0.0041$ ，说明生产力得分不能被当前特征稳定预测。这个对比提醒我们，不能因为某个目标预测效果好，就推断所有数字生活方式结果都能被有效预测。

聚类任务给出了三类探索性画像：高社交媒体使用型、高设备依赖型和低负荷均衡型。但 KMeans $k = 3$ 的 $\text{Silhouette}=0.1860$ ，聚类结构偏弱，因此画像更适合用于描述和讨论，而不是用于严格分群或自动化决策。

8.2 数字生活方式管理建议

从描述性分析和模型结果看，设备使用时长、通知暴露、解锁频率、社交媒体时长、睡眠时长和睡眠质量是报告中反复出现的变量。基于这些发现，可以提出以下温和建议：

- 关注设备使用时长。设备使用时长在分类和数字依赖回归中都具有较高解释价值，因此用户可以通过记录日均使用时间来了解自身数字负荷。
- 管理通知干扰。通知数量与数字依赖得分预测关系较强，减少不必要通知可能有助于降低注意力被打断的频率，但本文不声称通知减少必然导致健康改善。
- 合理安排社交媒体使用。聚类中的高社交媒体使用型具有明显的行为特征，说明社交媒体时长适合作为用户画像维度之一。
- 保证睡眠和活动。EDA 显示高风险组与非高风险组在睡眠时长和睡眠质量上存在描述性差异，因此睡眠和活动变量应在数字生活方式管理中被共同考虑。
- 对筛查结果进行人工复核。分类模型存在误报和漏判，模型输出只能作为初筛参考，不能替代人工判断、专业评估或个体实际情况。

8.3 方法局限

本文主要存在三方面限制。第一，数据为合成数据，变量关系可能反映生成机制而非真实世界机制。第二，本文使用传统机器学习模型和表格特征，未引入更复杂的时间序列或个体追踪信息，因此无法刻画长期变化。第三，聚类轮廓系数较低，用户画像解

释需要保持谨慎。后续若有真实纵向数据，可以进一步检验模型在真实场景中的泛化能力。

9 总结与个人反思

本章的目的在于总结本次课程报告的主要工作，并反思在大数据分析流程中需要特别注意的问题。本文完成了从数据集选择、合规性检查、预处理、EDA、分类、回归、聚类到 LaTeX 报告组织的完整流程。

9.1 主要结论

第一，2025 Digital Lifestyle Benchmark Dataset 满足本课程报告对公开表格数据、样本规模、字段数量和多任务建模的要求。数据共有 3500 条记录和 24 个字段，但其合成数据属性决定了本文结论只能用于课程建模和行为分析练习。

第二，分类任务在严格排除目标泄漏字段后，最终采用 Gradient Boosting 和 $\text{threshold}=0.14$ 的筛查策略，测试集 $\text{Recall}=0.6420$ 、 $\text{F1}=0.5355$ 、 $\text{PR-AUC}=0.5084$ 。该结果说明模型可以辅助识别一部分高风险样本，但不能作为诊断工具。

第三，回归任务显示 `digital_dependence_score` 更适合作为主线目标，最佳 $R^2 = 0.9839$ 、 $\text{MSE}=3.1471$ 、 $\text{MAE}=0.9982$ ；相比之下，`productivity_score` 的最佳 $R^2 = -0.0041$ ，属于弱预测/负结果。这个结果提醒我，实验报告不应只挑选效果好的目标，而应诚实呈现模型不能解决的问题。

第四，聚类任务在只使用数字行为与生活习惯数值特征的前提下得到三类探索性画像，但 KMeans $k = 3$ 的 $\text{Silhouette}=0.1860$ ，说明分群边界不清晰。因此，聚类结果适合用于描述用户画像，不适合用于严格分类。

9.2 课程收获

通过本次报告，我对大数据分析流程有了更完整的理解。数据分析不只是运行模型，还包括数据来源审查、字段含义理解、缺失与重复检查、异常范围检查、特征工程、目标泄漏控制、评价指标选择和结果解释。尤其是在分类任务中，如果只看 Accuracy，就会忽视高风险样本召回不足的问题；在回归任务中，如果只报告效果好的数字依赖目标，就会掩盖生产力预测失败这一重要事实。

本次实验也让我认识到负结果的价值。`productivity_score` 的预测效果较弱并不是报告失败，而是说明当前特征对该目标解释力有限。真实数据分析中，承认模型边界比给出过度结论更重要。

9.3 改进方向

后续可以从三个方向改进。第一，若能获得真实、匿名且合规的数字行为数据，可以检验当前模型在真实样本上的稳定性。第二，可以增加时间维度，例如连续多周的设备使用和睡眠记录，以分析行为变化而非单日静态状态。第三，聚类部分可以结合更多外部验证指标或专家解释，但在当前数据和 Silhouette 结果下，不宜继续强化分群结论。

A 附录：核心代码与复现实验说明

本附录说明项目代码结构、notebook 执行顺序和正文未展开的附录材料。完整代码位于项目目录中的 notebooks/、src/ 和 scripts/，正文只展示必要片段，避免用大段代码替代方法说明。

A.1 项目代码结构

- src/config.py: 路径、随机种子、目标变量、泄漏列、聚类输入白名单和结果输出路径配置。
- src/data_utils.py: 数据下载、读取、数据集合规检查和摘要输出。
- src/feature_engineering.py: 工程特征生成、任务级特征排除和预处理管道构造。
- src/model_utils.py: 分类、回归、聚类评估与指标输出函数。
- src/visualization.py: EDA 图、模型评估图和聚类画像图绘制函数。
- scripts/stage2_5_evidence_enhancement.py: 预处理质量检查、PCA 解释方差和最终报告图表清单生成脚本。

A.2 Notebook 执行顺序

复现实验时按以下顺序执行 notebook:

1. notebooks/00_dataset_selection_and_compliance.ipynb
2. notebooks/01_data_preprocessing_and_eda.ipynb
3. notebooks/02_classification_high_risk.ipynb
4. notebooks/03_regression_productivity.ipynb
5. notebooks/04_clustering_lifestyle_profiles.ipynb
6. notebooks/05_result_summary_for_report.ipynb

A.3 附录图表

图 17 展示主要数值变量直方图，作为第 4 章 EDA 的补充。图 18 展示行为变量与结果变量的散点或分箱关系，用于辅助观察变量关系。




图 17: 主要数值变量分布直方图




图 18: 行为变量与结果变量关系图

图 19 展示 `productivity_score` 的真实值与预测值对比。该图作为生产力弱预测结果的补充材料。图 20 展示分类任务置换重要性，用于补充解释分类模型主要依赖的输入变量。




图 19: 生产力得分真实值与预测值对比




图 20: 分类任务置换重要性

A.4 附录表格与结果文件

PCA 解释方差表作为附录材料列出前 10 个主成分，完整结果见 `results/pca_explained_variance.csv`。

表 10: PCA 解释方差附录表（前 10 个主成分）

主成分	解释方差比例	累计解释方差
PC1	0.2694	0.2694
PC2	0.1547	0.4241
PC3	0.1366	0.5607
PC4	0.1258	0.6865
PC5	0.1030	0.7895
PC6	0.0759	0.8654
PC7	0.0430	0.9084
PC8	0.0425	0.9509
PC9	0.0274	0.9783
PC10	0.0152	0.9935

分类调参完整结果保存在 `results/classification_cv_results.csv`, 数字依赖回归调参完整结果保存在 `results/regression_digital_dependence_cv_results.csv`。这些 CSV 文件列数较多, 正文不直接排版完整表格, 避免影响阅读; 正式提交时可作为附录电子材料与 notebook 一并提供。

A.5 参考资料与数据来源

1. Digital Lifestyle Benchmark Dataset (2025).
2. scikit-learn 官方文档。
3. 《大数据分析与应用》课程考查报告要求。