

湖北大学 2025-2026 学年度第 2 学期课程考查试题纸

The paper of course exam

Name: Big Data Analysis and Applications
Content: Course Report
Teacher: Li Jie

课程报告题目

《数字生活方式下的高风险识别、数字依赖预测与用户画像分析——基于 2025 Digital Lifestyle Benchmark 数据集的分类、回归与聚类研究》

学号: _____
姓名: _____
学院: _____
专业年级: _____
Institution: _____
Grade and major: _____

Teacher's comments: _____

Total score: _____
Grading teacher: _____

摘要

本文基于 2025 Digital Lifestyle Benchmark Dataset，围绕数字设备使用、社交媒体、通知暴露、睡眠、学习与身体活动等变量，开展数字生活方式下的高风险识别、数字依赖预测与用户画像分析。数据集包含 3500 条记录和 24 个字段，为合成教学与基准数据，本文所有结论仅用于《大数据分析与应用》课程建模训练和行为数据分析，不用于医学诊断或自动化干预。

研究设置三类任务：第一，分类任务以 `high_risk_flag` 为目标，在严格排除心理状态、效率得分和数字依赖得分等潜在泄漏字段后进行高风险数字生活方式筛查；第二，回归任务以 `digital_dependence_score` 为主线，同时保留 `productivity_score` 作为弱预测与负结果对照；第三，聚类任务只使用数字行为与生活习惯数值特征，构建探索性用户画像。实验均使用 CPU 环境下的 Python、pandas、numpy、scipy、matplotlib 与 scikit-learn 实现，随机过程统一设置 `random_state=42`。

已有实验结果显示，分类任务最终采用 Gradient Boosting 并选择 `threshold=0.14` 的偏召回筛查策略，测试集 `Recall=0.6420`、`F1=0.5355`、`PR-AUC=0.5084`；数字依赖回归的最佳模型为 Gradient Boosting，测试集 $R^2 = 0.9839$ 、`MSE=3.1471`、`MAE=0.9982`；生产力得分预测 $R^2 = -0.0041$ ，说明在当前可观测特征下不宜得出强预测结论；KMeans 在 $k = 3$ 时 `Silhouette=0.1860`，聚类结果仅用于探索性画像，不代表天然清晰人群边界。

关键词：数字生活方式；高风险识别；数字依赖预测；机器学习；聚类画像；大数据分析

目录

摘要	I
1 引言	1
1.1 背景与意义	1
1.2 研究目标与问题定义	1
1.3 本文主要工作	1
1.4 组织结构	2
2 相关理论与方法基础	3
2.1 标准数据分析流程	3
2.2 分类任务与评价指标	3
2.3 回归任务与评价指标	3
2.4 聚类分析与 PCA 降维	4
2.5 目标泄漏控制与模型验证原则	4
3 数据集与预处理	5
3.1 数据集来源与合规性说明	5
3.2 字段含义与任务变量设计	5
3.3 数据质量检查	6
3.4 特征工程与特征筛选	6
3.5 探索性统计与变量分布	7
4 方法设计与实验实现	8
4.1 总体技术路线	8
4.2 工程结构与核心文件组织	8
4.3 分类建模流程	8
4.4 回归建模流程	9
4.5 聚类画像流程	9
4.6 实验复现与结果文件组织	9
5 实验结果与分析	10
5.1 实验设置	10

5.2	探索性分析结果	10
5.3	高风险筛查分类实验	12
5.4	数字依赖预测与生产力弱预测	16
5.5	数字生活方式聚类画像	19
5.6	综合比较与结果边界分析	23
6	总结与展望	24
6.1	工作总结	24
6.2	应用价值	24
6.3	不足与局限性	24
6.4	后续改进	24
6.5	课程收获与个人反思	24
	参考文献	26
	附录 A 核心代码	27
A.1	核心源文件功能	27
A.2	核心流程片段	27
	附录 B 个人完成情况与独立性说明	29
	附录 C 项目链接与运行说明	30
C.1	GitHub 仓库地址	30
C.2	环境安装	30
C.3	Notebook 执行顺序	30
C.4	关键脚本与 Overleaf 包	30
	附录 D 补充图表与完整结果文件说明	32
D.1	补充图表	32
D.2	PCA 解释方差表	35
D.3	完整结果文件说明	36

1 引言

1.1 背景与意义

移动设备、社交媒体平台、在线学习工具和即时通知已经深度嵌入日常生活。用户每天面对的设备使用时长、手机解锁次数、通知数量、社交媒体使用时间、睡眠质量和身体活动频率，既是数字生活方式的重要表征，也是行为分析和数字健康管理中的常见观测变量。对这类数据进行建模，有助于理解数字行为数据如何支持风险筛查、依赖程度预测和用户画像构建。

本报告面向《大数据分析与应用》课程考查，重点不在于证明数字行为对身心状态存在因果影响，而在于完成一个较完整的数据分析流程：从数据集筛选、合规性说明、预处理、可视化分析，到分类、回归和聚类建模，再到对模型结果边界的解释。由于数据集为合成教学/基准数据，文中的“高风险”仅指数据集中给出的 `high_risk_flag` 标签，不代表医学诊断结果。

1.2 研究目标与问题定义

围绕数字生活方式变量，本文设置以下四个研究问题：

1. 能否在排除心理状态、效率得分和数字依赖得分等潜在目标泄漏字段后，对 `high_risk_flag` 进行高风险数字生活方式筛查？
2. 使用人口背景、数字行为、生活习惯和工程特征，能否稳定预测 `digital_dependence_score`？
3. `productivity_score` 是否能被当前可观测特征稳定预测；若不能，负结果本身说明什么？
4. 只基于数字行为与生活习惯数值特征，能否形成具有解释价值的探索性用户画像？

1.3 本文主要工作

本文主要完成以下工作。首先，选择 2025 Digital Lifestyle Benchmark Dataset 作为课程数据集，并核验其来源、数据规模、文件格式和任务适配性。其次，完成缺失值、重复值、合理范围、工程特征和任务级特征筛选检查，明确分类、回归与聚类中的变量使用边界。再次，使用 Logistic Regression、Random Forest、Gradient Boosting 等传统机器学习模型完成分类和回归实验，并通过交叉验证、超参数调优和阈值选择增强结果

可信度。最后，使用 KMeans、AgglomerativeClustering 和 GaussianMixture 比较聚类效果，并结合 PCA 可视化形成探索性画像。

1.4 组织结构

全文结构如下：第 2 章介绍分类、回归、聚类、PCA 和目标泄漏控制等方法基础；第 3 章说明数据集来源、字段含义、预处理质量检查和探索性统计；第 4 章给出总体技术路线、工程结构和三类建模流程；第 5 章集中展示探索性分析、分类、回归和聚类结果；第 6 章总结工作价值、局限性和后续改进方向。参考文献置于正文之后，附录给出核心代码、个人完成情况、项目链接与补充图表说明。

2 相关理论与方法基础

2.1 标准数据分析流程

标准数据分析流程通常包括问题定义、数据获取、数据质量检查、特征工程、探索性分析、模型训练、模型验证、结果解释和复现归档。本文按照该流程组织实验：先确认数据集满足课程对年份、规模、格式和任务类型的要求，再进行预处理与可视化，最后分别完成分类、回归和聚类建模。这样做的目的，是保证模型结果不是孤立指标，而是可以追溯到数据来源、变量选择和实验设置。

2.2 分类任务与评价指标

分类任务的目标是学习输入特征 X 与离散标签 y 之间的映射。本文分类任务预测 `high_risk_flag`，属于二分类筛查问题。除 Accuracy 外，本文更关注 Precision、Recall、F1、PR-AUC 和混淆矩阵，因为高风险筛查中漏判会降低模型的参考价值。

若 TP 、 FP 、 TN 、 FN 分别表示真正例、假正例、真负例和假负例，则主要指标定义为：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (2-1)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2-2)$$

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2-3)$$

Precision 反映被模型标为高风险的样本中有多少确为高风险，Recall 反映真实高风险样本中有多少被识别出来。F1 是 Precision 与 Recall 的调和平均，用于在二者之间取得综合评价。

2.3 回归任务与评价指标

回归任务用于预测连续型目标变量。本文以 `digital_dependence_score` 为主回归目标，同时保留 `productivity_score` 作为弱预测对照。评价指标包括 R^2 、MSE、RMSE

和 MAE:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (2-4)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (2-5)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (2-6)$$

MSE 与 RMSE 对较大误差更敏感, MAE 更直观地表示平均绝对偏差。\$R^2\$ 衡量模型相对均值预测的解释能力, 若 \$R^2\$ 接近 0 或为负, 说明当前特征和模型难以稳定预测该目标。

2.4 聚类分析与 PCA 降维

聚类分析不使用监督标签, 而是依据样本在特征空间中的相似性进行分组。本文比较 KMeans、AgglomerativeClustering 和 GaussianMixture, 并使用肘部法则、Silhouette、Calinski-Harabasz 和 Davies-Bouldin 等指标辅助判断。

Silhouette 衡量样本与本簇和邻近簇之间的相对距离。对样本 \$i\$, 设 \$a(i)\$ 为其到同簇样本的平均距离, \$b(i)\$ 为其到最近其他簇样本的平均距离, 则:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}. \quad (2-7)$$

Silhouette 越高通常表示簇内更紧凑、簇间更分离。本文的聚类 Silhouette=0.1860, 说明分群边界偏弱, 因此聚类结果只作为探索性用户画像。

PCA 用于将高维标准化特征投影到少数主成分上, 便于可视化和辅助理解。本文的 PCA 不作为分类或回归模型输入, 也不用于因果解释。

2.5 目标泄漏控制与模型验证原则

目标泄漏指模型训练时使用了与目标变量高度重合或由目标派生的信息, 导致测试指标虚高但实际不可用。本文在分类预测 `high_risk_flag` 时, 明确排除 `anxiety_score`、`depression_score`、`stress_level`、`happiness_score`、`focus_score`、`productivity_score` 和 `digital_dependence_score` 等 `outcome` 字段。回归任务也排除 `high_risk_flag`、心理状态结果变量和另一个 `outcome` 目标变量。聚类任务只使用数字行为与生活习惯数值特征, 将背景类别和结果变量仅用于聚类后的画像解释。

模型验证方面, 分类任务使用 StratifiedKFold、超参数搜索和独立测试集评估; 阈值选择在验证集上完成, 最终测试集只评估一次。回归任务使用交叉验证选择超参数, 并在测试集报告最终指标。聚类任务不使用监督标签训练, 而是用多种内部指标和可视化结果共同判断分群是否稳定。

3 数据集与预处理

3.1 数据集来源与合规性说明

本文使用 2025 Digital Lifestyle Benchmark Dataset。该数据集以 CSV 形式提供，包含 3500 条记录和 24 个字段，支持分类、回归和聚类任务。表 3-1 给出数据集合规性摘要。数据集为合成数据，适合课程教学、benchmark 和 EDA 场景，但不适合直接外推到真实医学诊断或个体健康判定。

表 3-1 数据集合规性摘要

检查项	结果
数据集名称	2025 Digital Lifestyle Benchmark Dataset
来源页面	https://huggingface.co/datasets/tarekmasryo/digital-lifestyle-benchmark-dataset
文件格式	CSV
样本量	3500
字段数	24
许可说明	CC BY 4.0（依据数据集页面说明）
随机种子	42
计算环境	CPU only
深度学习	False

在数据集选择阶段，本文没有采用 `pfm_train.csv`/`pfm_test.csv`。原因是该员工离职类数据与前序实验主题相似度较高，且来源年份与课程要求中的 2024-2025 更新约束不如当前数据集清晰。Digital Lifestyle 数据集更贴合数字生活方式主题，并自然支持本报告设置的分类、回归与聚类任务。

3.2 字段含义与任务变量设计

原始字段覆盖人口背景、设备使用、生活习惯和结果变量四类信息。人口背景包括年龄、性别、地区、收入、教育、日常角色和设备类型；设备使用包括每日设备时长、手机解锁次数、通知数量、社交媒体使用时间等；生活习惯包括学习时间、身体活动天数、睡眠时长和睡眠质量；结果变量包括高风险标记、生产力得分、数字依赖得分以及若干心理状态相关字段。

本文据此设计三类任务：分类任务预测 `high_risk_flag`；回归任务以 `digital_dependence_score` 为主线，同时检验 `productivity_score` 的可预测性；聚类任务只基于数字行为与生活习惯数值特征形成用户画像。

3.3 数据质量检查

预处理质量检查结果见表 3-2。原始数据共 3500 条记录、24 个字段，缺失值总数为 0，重复行数量为 0，重复 id 数量为 0。关键数值字段的范围检查均通过，包括年龄、设备时长、解锁次数、通知数、社交媒体时长、学习时长、身体活动天数、睡眠时长、睡眠质量、生产力得分和数字依赖得分。检查后未发现需要删除的记录。

表 3-2 预处理质量检查摘要

检查项	检查结果	处理策略
原始样本量	3500	未删除记录
原始字段数	24	未删除字段
缺失值总数	0	无需删除，建模管道保留缺失处理能力
重复行数量	0	无需删除
重复 id 数量	0	无需删除
关键数值字段合理范围	全部通过	检查后未发现需删除记录
工程特征生成	7 个特征全部生成	用于补充行为比例和交互信息
分类泄漏字段排除	通过	排除 <code>outcome</code> 字段与 <code>id</code>
回归 <code>outcome</code> 控制	通过	排除 <code>high_risk_flag</code> 和其他结果变量
聚类输入控制	通过	仅使用行为与生活习惯数值特征

3.4 特征工程与特征筛选

特征工程主要从行为变量中派生比例和交互特征，包括 `social_media_hours`、`study_hours`、`notifications_per_device_hour`、`unlocks_per_device_hour`、`device_to_sleep_ratio`、`activity_sleep_interaction` 和 `social_to_study_ratio`。这些特征用于补充原始时长和计数字段，使模型能捕捉单位设备时长下的通知或解锁压力，以及设备使用与睡眠、活动之间的相对关系。

为防止目标泄漏，分类任务排除所有身心结果变量、效率变量、数字依赖变量和 `id`；回归任务排除 `high_risk_flag`、心理状态结果字段和另一个 `outcome` 目标变量；聚类

任务使用显式白名单，只包含数字行为与生活习惯数值特征。

Listing 3.1 任务级特征排除逻辑示意

```
CLASSIFICATION_LEAKAGE = [  
    "anxiety_score", "depression_score", "stress_level",  
    "happiness_score", "focus_score", "productivity_score",  
    "digital_dependence_score", "high_risk_flag", "id"  
]  
  
CLUSTERING_FEATURES = [  
    "device_hours_per_day", "phone_unlocks", "notifications_per_day",  
    "social_media_mins", "study_mins", "physical_activity_days",  
    "sleep_hours", "sleep_quality", "social_media_hours",  
    "study_hours", "notifications_per_device_hour",  
    "unlock_per_device_hour", "device_to_sleep_ratio",  
    "activity_sleep_interaction", "social_to_study_ratio"  
]
```

3.5 探索性统计与变量分布

探索性统计用于在建模前理解类别比例、数值变量分布和变量相关性。本文将主要 EDA 图放在第 5 章结果分析中集中解释，附录保留数值变量直方图和行为变量-结果变量关系图。这样的组织方式可以避免数据预处理章节过长，同时让读者在结果章节中同时看到可视化证据和模型指标。

4 方法设计与实验实现

4.1 总体技术路线

本文技术路线遵循“数据合规性检查-预处理与特征工程-探索性分析-监督学习建模-无监督画像-结果归档”的顺序。图 4-1 用流程图概括整体路径。

数据集选择与合规性检查 → 数据质量检查 → 特征工程与特征筛选 → EDA 可视化 → 分类/回归建模 → 聚类与 PCA 画像 → 图表、CSV 与 LaTeX 报告归档

图 4-1 总体数据分析技术路线

4.2 工程结构与核心文件组织

项目采用 notebooks、src、scripts、results、figures 和 report/overleaf 包分离的方式组织，便于复现实验与撰写报告。图 4-2 展示了核心目录职责。

目录	作用
data/	保存原始数据与处理后数据，不在 Stage 5 中修改。
notebooks/	记录数据选择、EDA、分类、回归、聚类和结果汇总过程。
src/	保存配置、数据工具、特征工程、可视化和模型评估函数。
scripts/	保存证据增强、检查和报告辅助脚本。
results/	保存所有 CSV、Markdown 和文本结果，是报告指标来源。
figures/	保存 EDA、模型评估、聚类和 PCA 图片。
overleaf_final/	保存可上传 Overleaf 的自包含 LaTeX 编译包。

图 4-2 项目工程目录与核心文件组织

4.3 分类建模流程

分类任务以 `high_risk_flag` 为目标。建模时先完成目标泄漏字段排除，再将数据划分为训练集、验证集和测试集。模型包括 Logistic Regression、Random Forest 和 Gradient Boosting，并使用 StratifiedKFold 进行交叉验证和超参数搜索。阈值选择不直

接使用测试集，而是在验证集上比较默认阈值、最大 F1 阈值和不同 Recall 约束下的策略，最终在测试集上报告一次结果。

4.4 回归建模流程

回归任务分为两个目标: `digital_dependence_score` 和 `productivity_score`。两者使用相同的特征控制原则，即不使用 `high_risk_flag`、心理状态结果字段以及另一个 outcome 目标变量。模型包括 Linear Regression、Ridge、RandomForestRegressor 和 GradientBoostingRegressor。最终评价指标包括 R^2 、MSE、RMSE 和 MAE。

4.5 聚类画像流程

聚类任务不使用监督标签训练，只使用数字行为与生活习惯数值特征，并在建模前进行 StandardScaler 标准化。KMeans 测试 $k = 2$ 到 $k = 8$ ，并与 AgglomerativeClustering、GaussianMixture 进行比较。聚类完成后，再用 `high_risk_flag`、`productivity_score`、`digital_dependence_score` 和背景变量进行画像解释。

4.6 实验复现与结果文件组织

实验使用 CPU 环境，主要依赖 Python、pandas、numpy、scipy、matplotlib 和 scikit-learn。所有随机过程统一设置 `random_state=42`。模型指标来自 `results/` 目录中的 CSV 或文本文件，图片来自 `figures/`。Stage 5 只重构 LaTeX 报告结构和 Overleaf 编译包，不新增实验、不重跑模型，也不修改任何核心 CSV 指标。

5 实验结果与分析

5.1 实验设置

本文所有模型均在 CPU 环境下运行，不使用 GPU 和深度学习。分类、回归和聚类均基于 scikit-learn 实现，数值处理和结果整理使用 pandas、numpy 和 scipy，可视化使用 matplotlib。监督学习任务采用训练/测试划分和交叉验证调参，随机过程统一设置 `random_state=42`。正文中的指标均来自已有 `results/` 文件。

5.2 探索性分析结果

图 5-1 显示 `high_risk_flag` 的类别分布。高风险样本并非多数类，因此分类任务不能只看 Accuracy；若模型倾向预测低风险，可能在准确率较高的同时漏掉大量高风险样本。




图 5-1 `high_risk_flag` 类别分布

图 5-2 展示数值变量相关性。相关性热力图主要用于识别变量之间的线性关联和潜在冗余，不用于推断因果关系。




图 5-2 数值变量相关性热力图

图 5-3 比较不同风险组在设备使用、通知、社交媒体、睡眠与活动变量上的分布差异。这些图可以帮助解释模型为什么关注部分行为变量，但仍然只能作为描述性证据。




图 5-3 按高风险标记分组的行为变量箱线图

图 5-4 展示类别变量下的高风险比例。该图用于观察背景类别与风险标记之间的描

述性差异，不能解释为类别本身导致风险变化。




图 5-4 类别变量下的高风险比例

5.3 高风险筛查分类实验

分类实验比较 Logistic Regression、Random Forest 和 Gradient Boosting，并在调参后对 Gradient Boosting 进行阈值选择。表 5-1 是验证集阈值调优结果，表 5-2 是测试集最终指标。最终选择 threshold=0.14，是因为该策略在验证集上满足 Recall 至少 0.60 的约束，并在测试集上取得 Recall=0.6420、F1=0.5355、PR-AUC=0.5084。

表 5-1 验证集阈值调优结果

模型	阈值策略	阈值	Precision	Recall	F1	PR-AUC	Balanced Accuracy
Gradient Boosting	default_0_50	0.5000	0.6429	0.2045	0.3103	0.4805	0.5880
Gradient Boosting	max_f1	0.3500	0.5752	0.4924	0.5306	0.4805	0.7005
Gradient Boosting	recall_at_least_60_best_precision	0.1400	0.4175	0.6136	0.4969	0.4805	0.6992
Gradient Boosting	recall_at_least_70_best_precision	0.1200	0.2636	0.7727	0.3931	0.4805	0.6149

表 5-2 测试集分类指标与阈值策略对比

模型	阈值策略	阈值	Precision	Recall	F1	ROC-AUC	PR-AUC	Balanced Accuracy
Gradient Boosting	default_0_50	0.5000	0.6812	0.2670	0.3837	0.7531	0.5084	0.6178
Gradient Boosting	max_f1	0.3500	0.5957	0.4773	0.5300	0.7531	0.5084	0.6979
Gradient Boosting	recall_at_least_60_best_precision	0.1400	0.4593	0.6420	0.5355	0.7531	0.5084	0.7259
Gradient Boosting	recall_at_least_70_best_precision	0.1200	0.2536	0.7955	0.3846	0.7531	0.5084	0.6030

图 5-5 展示不同阈值策略下的分类指标对比。默认阈值 0.50 的 Precision 较高，但 Recall 偏低；threshold=0.14 则牺牲部分 Precision 以提升高风险样本召回，更符合筛查任务对漏判控制的需求。




图 5-5 分类阈值策略指标对比

图 5-6 为最终阈值下的混淆矩阵，测试集中 $TN = 566$ 、 $FP = 133$ 、 $FN = 63$ 、 $TP = 113$ 。该结果说明模型能识别部分高风险样本，但仍存在误报和漏报，因此只能作为初筛工具，不能作为医学诊断工具。




图 5-6 最终分类混淆矩阵

PR 曲线和 ROC 曲线分别见图 5-7 与图 5-8。在类别不均衡和高风险筛查场景下，PR-AUC 对正类识别能力更敏感；ROC-AUC 则用于补充观察整体排序能力。




图 5-7 分类 Precision-Recall 曲线




图 5-8 分类 ROC 曲线

5.4 数字依赖预测与生产力弱预测

回归任务以 `digital_dependence_score` 为主线，并将 `productivity_score` 作为对照。表 5-3 显示两个目标的最佳模型均为 Gradient Boosting，但预测效果差异明显：数字依赖预测 $R^2 = 0.9839$ 、 $MSE=3.1471$ 、 $MAE=0.9982$ ；生产力预测 $R^2 = -0.0041$ ，比简单均值预测更弱。

表 5-3 两个回归目标的最佳模型对比

目标变量	最佳模型	MAE	MSE	RMSE	R^2	CV 最优 R^2
<code>productivity_score</code>	Gradient Boosting	7.1671	85.2031	9.2306	-0.0041	0.0119
<code>digital_dependence_score</code>	Gradient Boosting	0.9982	3.1471	1.7740	0.9839	0.9804

表 5-4 给出数字依赖预测中各模型的测试指标。Gradient Boosting 在该目标上表现

最好，说明数字依赖得分与设备使用时长、通知数、解锁次数等行为变量之间具有较强的可预测关系。这里仍需强调，可预测关系不等同于因果关系。

表 5-4 digital_dependence_score 回归模型测试集指标

模型	MAE	MSE	RMSE	R^2
Gradient Boosting	0.9982	3.1471	1.7740	0.9839
Ridge	0.7652	3.6541	1.9116	0.9813
Linear Regression	0.7651	3.6538	1.9115	0.9813
Random Forest	1.2680	4.3875	2.0946	0.9776

图 5-9 和图 5-10 进一步展示两个回归目标的效果差异。数字依赖预测中真实值与预测值接近对角线，说明拟合效果较好。



图 5-9 两个回归目标预测效果对比




图 5-10 数字依赖得分真实值与预测值对比

图 5-11 显示数字依赖预测的置换重要性。重要变量主要集中在 `device_hours_per_day`、`notifications_per_day` 和 `phone_unlocks` 等行为指标，这与数字依赖得分的业务含义一致。




图 5-11 数字依赖预测置换重要性

生产力得分结果见表 5-5。该目标的 R^2 为负，说明当前可观测数字行为、生活习惯和背景变量不足以稳定预测生产力得分。这个负结果具有方法价值：它提醒我们不能因为某些目标可以被良好预测，就推断同一套特征对所有结果变量都有效。

表 5-5 productivity_score 回归模型测试集指标

模型	MAE	MSE	RMSE	R^2
Gradient Boosting	7.1671	85.2031	9.2306	-0.0041
Random Forest	7.2088	85.9208	9.2693	-0.0125
Ridge	7.1747	85.5884	9.2514	-0.0086
Linear Regression	7.1999	85.8232	9.2641	-0.0114

5.5 数字生活方式聚类画像

聚类实验只使用数字行为与生活习惯数值特征，不使用背景类别和 outcome 字段训练。表 5-6 比较了 KMeans、AgglomerativeClustering 和 GaussianMixture 的内部指标。KMeans 在 $k = 3$ 时 Silhouette=0.1860，结合可解释性选择为最终画像方案。

表 5-6 聚类算法与簇数对比摘要

算法	k	Silhouette	Calinski-Harabasz	Davies-Bouldin
KMeans	2	0.1808	752.8023	1.9065
KMeans	3	0.1860	611.1770	1.7959
KMeans	4	0.1406	546.4364	1.9615
Agglomerative	3	0.1518	495.8938	1.8768
GaussianMixture	2	0.1478	650.8461	2.1599
GaussianMixture	4	0.1225	408.1725	2.2266

图 5-12 和图 5-13 分别给出 KMeans 肘部曲线和不同算法/簇数的 Silhouette 对比。Silhouette 数值整体不高，说明聚类结构偏弱，不能把三类画像解释为天然清晰分群。




图 5-12 KMeans 肘部曲线




图 5-13 不同聚类算法与簇数的 Silhouette 对比

PCA 累计解释方差见图 5-14。前两个主成分累计解释方差为 0.4241，前五个主成分累计解释方差为 0.7895。PCA 在本文中仅用于降维可视化和辅助理解，不作为因果解释。




图 5-14 PCA 累计解释方差曲线

图 5-15 展示聚类结果在前两个 PCA 维度上的投影。不同簇之间存在一定分离趋势，但重叠仍然明显，这与较低 Silhouette 指标一致。




图 5-15 数字生活方式聚类的 PCA 可视化

表 5-7 和图 5-16 展示三类探索性画像。Cluster 0 可概括为高社交媒体使用型，Cluster 1 可概括为高设备依赖型，Cluster 2 可概括为低负荷均衡型。这些命名用于描述簇均值特征，不代表固定人群标签。

表 5-7 数字生活方式聚类画像精简表

簇	样本数	设备时长	社交媒体分钟	睡眠时长	睡眠质量	高风险比例	数字依赖分	建议画像名称
Cluster 0	447	6.9533	430.2125	7.3816	2.7899	0.1969	34.3296	高社交媒体使用型
Cluster 1	1039	11.0538	131.8787	6.1218	1.6953	0.3725	51.2425	高设备依赖型
Cluster 2	2014	5.4711	113.4275	7.8106	3.2137	0.1142	29.6962	低负荷均衡型




图 5-16 聚类画像标准化特征热力图

5.6 综合比较与结果边界分析

综合三类任务可以看到，分类模型在 $\text{threshold}=0.14$ 下更适合作为偏召回的高风险初筛工具；数字依赖得分可预测性强，适合作为回归主线；生产力得分在当前特征下预测较弱，应作为负结果分析；聚类结果能够形成有解释价值的探索性画像，但边界不清晰。由于数据集为合成数据，且实验基于相关性和预测关系，本文不作医学诊断、不作个体因果推断，也不建议将模型结果直接用于自动化干预。

6 总结与展望

6.1 工作总结

本文围绕 2025 Digital Lifestyle Benchmark Dataset 完成了一个完整的大数据分析课程项目。工作内容包括数据集筛选与合规性说明、数据质量检查、工程特征构造、探索性可视化、分类筛查、回归预测、聚类画像和 LaTeX 报告整理。实验结果表明，数字依赖得分在当前特征下具有较强可预测性，高风险标记可以通过偏召回阈值策略进行初筛，而生产力得分预测较弱，聚类结果更适合用于探索性画像。

6.2 应用价值

从课程应用角度看，本文展示了如何在一个主题统一的数据集中同时组织分类、回归和聚类任务。分类部分强调不能只看 Accuracy，需要结合 Recall、F1、PR-AUC 和混淆矩阵选择筛查策略；回归部分说明不同目标变量的可预测性差异；聚类部分展示了如何在不使用 outcome 字段训练的情况下形成用户画像，并用结果变量进行事后解释。

6.3 不足与局限性

本文存在若干局限。首先，数据集为合成数据，不能代表真实人群行为规律。其次，本文使用的是传统机器学习模型和表格特征，没有引入更复杂的时序或上下文信息。第三，分类任务的 PR-AUC 和 F1 仍有提升空间，误报和漏报都存在。第四，聚类 Silhouette=0.1860，说明分群边界较弱，聚类画像只能作为描述性探索。

6.4 后续改进

后续可以从三个方向改进。第一，在真实、合规、匿名化的数据上验证模型稳定性。第二，引入更细粒度的时间特征，例如夜间设备使用、通知集中度和连续睡眠变化。第三，进一步比较模型解释方法和阈值选择策略，使高风险筛查结果更适合人工复核流程。

6.5 课程收获与个人反思

通过本项目，我进一步理解了数据分析不能只追求指标大小，还要关注数据来源、目标泄漏、任务定义和结果边界。特别是在生产力预测为负结果、聚类边界较弱的情况下，诚实报告模型不能支持的结论，比强行写出“显著影响”更重要。这个过程也让我

熟悉了将 notebook、src 工具函数、结果 CSV、图表文件和 LaTeX 报告组织为可复现项目的完整流程。

参考文献

1. Digital Lifestyle Benchmark Dataset (2025). Hugging Face Dataset: <https://huggingface.co/datasets/tarekmasryo/digital-lifestyle-benchmark-dataset>.
2. scikit-learn 官方文档: <https://scikit-learn.org/stable/>.
3. Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 2011, 12: 2825–2830.
4. 《大数据分析与应用》课程考查报告要求。
5. pandas、numpy、matplotlib 官方文档及其 Python 数据分析工具说明。

附录 A 核心代码

本附录说明报告涉及的核心代码结构。完整代码位于项目根目录的 `notebooks/`、`src/` 和 `scripts/`，正文只保留少量关键片段，避免用大段代码替代方法解释。

A.1 核心源文件功能

- `src/config.py`: 配置路径、随机种子、目标变量、泄漏字段、聚类输入白名单和输出目录。
- `src/data_utils.py`: 负责数据下载、读取、合规性检查和数据摘要输出。
- `src/feature_engineering.py`: 负责工程特征生成、任务级特征筛选和预处理管道构造。
- `src/model_utils.py`: 封装分类、回归、聚类评估指标和结果保存函数。
- `src/visualization.py`: 绘制 EDA 图、模型评估图、聚类画像图和 PCA 图。
- `scripts/stage2_5_evidence_enhancement.py`: 生成预处理质量检查、PCA 解释方差和报告图表筛选清单。

A.2 核心流程片段

Listing A.1 实验随机性与 CPU 传统机器学习约束示意

```
RANDOM_STATE = 42

models = {
    "logistic_regression": LogisticRegression(max_iter=2000),
    "random_forest": RandomForestClassifier(random_state=RANDOM_STATE),
    "gradient_boosting": GradientBoostingClassifier(random_state=RANDOM_STATE),
}
```

Listing A.2 阈值选择流程示意

```
threshold_candidates = [
    ("default_0_50", 0.50),
    ("max_f1", best_f1_threshold),
    ("recall_at_least_60_best_precision", recall60_threshold),
    ("recall_at_least_70_best_precision", recall70_threshold),
]
```

```
# Thresholds are selected on validation data.  
# The test set is evaluated once after the threshold is fixed.
```

附录 B 个人完成情况与独立性说明

本项目围绕《大数据分析与应用》课程考查要求独立完成，未复制旧实验报告内容。个人完成情况包括：

- 完成数据集筛选，比较课程要求、数据来源、发布时间、CSV 格式、样本规模和任务适配性。
- 设计分类、回归和聚类三类实验方案，并明确不使用深度学习和 GPU。
- 编写 Python 代码完成数据读取、预处理、工程特征、EDA、分类、回归、聚类、PCA 和结果汇总。
- 对分类任务进行目标泄漏控制、超参数调优和阈值选择。
- 对回归任务分别报告数字依赖强预测和生产力弱预测结果。
- 对聚类任务控制输入特征范围，并将聚类结果解释为探索性画像。
- 整理 results、figures、report/tables 和 overleaf_final 编译包，完成 LaTeX 正式报告写作与格式规范化。

报告中的指标均来自自己运行生成的结果文件，不编造未运行实验结论。对模型不能支持的部分，例如生产力得分弱预测和聚类边界较弱，也在正文中如实说明。

附录 C 项目链接与运行说明

C.1 GitHub 仓库地址

项目代码与报告文件保存在 GitHub 仓库: <https://github.com/hansu650/Big-Data-Homework>

本报告对应项目目录为: 期末考查报告 _ 数字生活方式分析/。

C.2 环境安装

建议使用课程环境或本地 Python 环境安装依赖:

Listing C.1 环境安装命令示意

```
pip install -r requirements.txt
```

若使用本机已有 conda 环境, 可先进入项目目录后运行 notebook 或脚本。所有实验使用 CPU, 不依赖 GPU。

C.3 Notebook 执行顺序

1. notebooks/00_dataset_selection_and_compliance.ipynb
2. notebooks/01_data_preprocessing_and_eda.ipynb
3. notebooks/02_classification_high_risk.ipynb
4. notebooks/03_regression_productivity.ipynb
5. notebooks/04_clustering_lifestyle_profiles.ipynb
6. notebooks/05_result_summary_for_report.ipynb

C.4 关键脚本与 Overleaf 包

证据增强脚本可重新生成预处理质量检查、PCA 解释方差和报告图表筛选清单:

Listing C.2 Stage 2.5 证据增强脚本

```
python scripts/stage2_5_evidence_enhancement.py
```

最终 Overleaf 编译包位于：期末考查报告 _ 数字生活方式分析/overleaf_final/。上传该目录到 Overleaf 后,选择 XeLaTeX 编译即可。最终提交时建议同时提交 main.pdf 与完整项目代码目录或仓库链接，以满足完整代码附录要求。

附录 D 补充图表与完整结果文件说明

D.1 补充图表

图 D-1 展示主要数值变量分布，作为探索性分析的补充材料。




图 D-1 主要数值变量分布直方图

图 D-2 展示行为变量与结果变量之间的关系，用于辅助观察变量联系，不作为因果证据。




图 D-2 行为变量与结果变量关系图

图 D-3 展示 `productivity_score` 的真实值与预测值对比。该图与正文中的负结果分析一致，说明生产力得分在当前特征下预测较弱。




图 D-3 生产力得分真实值与预测值对比

图 D-4 展示分类任务置换重要性，用于补充说明模型主要依赖的输入变量。




图 D-4 分类任务置换重要性

D.2 PCA 解释方差表

表 D-1 列出前 10 个主成分的解释方差比例。PCA 仅用于可视化和辅助理解，不作为分类或回归模型输入。

表 D-1 PCA 解释方差附录表（前 10 个主成分）

主成分	解释方差比例	累计解释方差
PC1	0.2694	0.2694
PC2	0.1547	0.4241
PC3	0.1366	0.5607
PC4	0.1258	0.6865
PC5	0.1030	0.7895
PC6	0.0759	0.8654
PC7	0.0430	0.9084
PC8	0.0425	0.9509
PC9	0.0274	0.9783
PC10	0.0152	0.9935

D.3 完整结果文件说明

完整结果文件保存在项目根目录的 `results/` 中。正文只排版精简表格，完整 CSV 作为电子附录保留，包括：

- `classification_cv_results.csv`: 分类超参数搜索完整结果。
- `classification_tuned_metrics.csv`: 分类阈值策略测试集指标。
- `regression_digital_dependence_cv_results.csv`: 数字依赖回归调参结果。
- `regression_productivity_metrics.csv`: 生产力弱预测结果。
- `clustering_model_comparison.csv`: 聚类算法和簇数对比。
- `clustering_lifestyle_profiles.csv`: 完整聚类画像表。
- `pca_explained_variance.csv`: 完整 PCA 解释方差表。